


Agente RAG para consultar 10-K

- Alex García
- Borja Castelló
- Mateo Santos
- Rodolfo Villena





Agente RAG para consultar 10-K

XBRL + Retrieval + Tools + Evaluación trazable

100%

Accuracy

20/20 en golden propio

\$0,0122

Coste medio
por pregunta

8,73s

Latencia media
por pregunta

4,05

Llamadas
tools/pregunta

20 preguntas - 6 compañías – 10-K – FY2024-FY2025

Problema:

las preguntas mezclan datos y explicación

No todas las respuestas viven en el mismo sitio

Cifras estructuradas

- Revenue, net income, assets,...
- Fuente: XBRL
- Verificación determinista


Texto Narrativo

- Riesgos, estrategia, guidance,...
- Fuente: fragmentos del 10-K
- Cita + chunk_id obligatorios

❏ **La dificultad real:** combinar ambas rutas sin inventar datos.

Arquitectura final

Mismo agente, herramientas especializadas y controles de salida.



Pregunta

Agente

Herramientas

Respuesta

4 tolos – BGE-small-en-v1.5 – FAISS + BM25 - RRF

Evolución experimental

Una variable por iteración, midiendo impacto real.

Versión	Cambio	Decisión
Baseline	Dense + XBRL + agente	Referencia
V1	Mejor routing por prompt	Mejora eficiencia
V2	Métricas S2 y evaluadores	Marco final
V3	Metadata, BM25, rewriting	Medir retrieval
Final	Dense + BM25/RRF + guardrails	Congelada

Resultado final en el golden propio

Mejora global y menor coste operativo en todas las métricas.




Mejoras clave:

- Accuracy: +10pp
- Coste: -28%
- Latencia: -18%
- Llamadas: -24%

Qué aprendimos sobre retrieval

El mejor ranking aislado no siempre es el mejor sistema.



Último experimento: BGE-M3 y docstrings largos

Un embedding mayor o mejores descripciones, ¿cambian el resultado?

Var.	Embedding	Docs	Accuracy	Recall@5	Coste
A	BGE-small	Cortos	100%	61,5%	\$0,0116
B	BGE-M3	Cortos	95%	61,5%	\$0,0144
C	BGE-small	Largos	100%	61,5%	\$0,0143

Robustez: no solo «acertar»

Cada respuesta tiene que poder auditarse.

Cifra

XBRL verifica cifra

Texto


Guardrail · chunk_id

Trayectoria

Tools usadas

- ❑ El evaluador comprueba cifra, cita y herramientas – no solo la respuesta final. El holdout se ejecutará sin tocar el sistema.





Qué defendería como aportación principal

No ganamos por usar el modelo más grande, sino por diseñar bien el sistema.

Separación de fuentes

Cifras estructuradas vs. texto narrativo: más importante que cambiar embeddings.

Docstrings estratégicos

Influyen en el routing, pero también cuestan tokens.

Agente compensa retrieval

Formula mejores búsquedas ante retrieval imperfecto.

Trazabilidad como clave

Cita, chunk_id y herramientas: base de la confianza.

Estado final y holdout

La práctica queda congelada antes de ver las 10 preguntas finales.

20/20

Golden propio

4

Herramientas
Contractuales


10

Preguntas holdout
Sin tocar código



Versión congelada
Antes de exposición

- ❑ En la exposición ejecutaremos `evaluar("holdout.jsonl")` y presentaremos el resultado sin reajustar el sistema.



Resultado del holdout ciego

Ejecutado sin reajustar el agente. La versión es la que congelamos.

8/10

ACIERTOS SOBRE 10 PREGUNTAS NUEVAS

8 aciertos

Todas las preguntas con respuesta en el corpus.

3 extractivas · 4 comparativas · 1 numérica


2 fallos

Los dos casos negativos, de abstención.

El agente detectó la ausencia del dato,
pero siguió buscando en vez de declararla.

La diferencia con el 20/20 está entera en una familia que nuestro golden set no contenía:
preguntas sin respuesta. No es un fallo de generalización, es un hueco de cobertura.

Agente RAG para consultar 10-K



¿Preguntas?

