


# Agente RAG para consultar 10-K

- Alex García
- Borja Castelló
- Mateo Santos
- Rodolfo Villena





# Agente RAG para consultar 10-K

XBRL + Retrieval + Tools + Evaluación trazable

**100%**

Accuracy

20/20 en golden propio

**\$0,0122**

Coste medio  
por pregunta

**8,73s**

Latencia media  
por pregunta

**4,05**

Llamadas  
tools/pregunta

20 preguntas - 6 compañías – 10-K – FY2024-FY2025

# Problema: las preguntas mezclan datos y explicación

No todas las respuestas viven en el mismo sitio

## Cifras estructuradas

- Revenue, net income, assets,...
- Fuente: XBRL
- Verificación determinista


## Texto Narrativo

- Riesgos, estrategia, guidance,...
- Fuente: fragmentos del 10-K
- Cita + chunk\_id obligatorios

❏ **La dificultad real:** combinar ambas rutas sin inventar datos.

# Arquitectura final

Mismo agente, herramientas especializadas y controles de salida.



Pregunta

Agente

Herramientas

Respuesta

4 tolos – BGE-small-en-v1.5 – FAISS + BM25 - RRF

# Evolución experimental

Una variable por iteración, midiendo impacto real.

| Versión  | Cambio                        | Decisión          |
|----------|-------------------------------|-------------------|
| Baseline | Dense + XBRL + agente         | Referencia        |
| V1       | Mejor routing por prompt      | Mejora eficiencia |
| V2       | Métricas S2 y evaluadores     | Marco final       |
| V3       | Metadata, BM25, rewriting     | Medir retrieval   |
| Final    | Dense + BM25/RRF + guardrails | Congelada         |

# Resultado final en el golden propio

Mejora global y menor coste operativo en todas las métricas.




## Mejoras clave:

- Accuracy: +10pp
- Coste: -28%
- Latencia: -18%
- Llamadas: -24%

# Qué aprendimos sobre retrieval

El mejor ranking aislado no siempre es el mejor sistema.



# Último experimento: BGE-M3 y docstrings largos

Un embedding mayor o mejores descripciones, ¿cambian el resultado?

| Var. | Embedding | Docs   | Accuracy | Recall@5 | Coste    |
|------|-----------|--------|----------|----------|----------|
| A    | BGE-small | Cortos | 100%     | 61,5%    | \$0,0116 |
| B    | BGE-M3    | Cortos | 95%      | 61,5%    | \$0,0144 |
| C    | BGE-small | Largos | 100%     | 61,5%    | \$0,0143 |

# Robustez: no solo «acertar»

Cada respuesta tiene que poder auditarse.

## Cifra

XBRL verifica cifra

## Texto


Guardrail · chunk\_id

## Trayectoria

Tools usadas

- ❑ El evaluador comprueba cifra, cita y herramientas – no solo la respuesta final. El holdout se ejecutará sin tocar el sistema.





# Qué defendería como aportación principal

No ganamos por usar el modelo más grande, sino por diseñar bien el sistema.

## Separación de fuentes

Cifras estructuradas vs. texto narrativo: más importante que cambiar embeddings.

## Docstrings estratégicos

Influyen en el routing, pero también cuestan tokens.

## Agente compensa retrieval

Formula mejores búsquedas ante retrieval imperfecto.

## Trazabilidad como clave

Cita, chunk\_id y herramientas: base de la confianza.

# Estado final y holdout

La práctica queda congelada antes de ver las 10 preguntas finales.

**20/20**

Golden propio

**4**

Herramientas  
Contractuales


**10**

Preguntas holdout  
Sin tocar código




Versión congelada  
Antes de exposición

- ❑ En la exposición ejecutaremos `evaluar("holdout.jsonl")` y presentaremos el resultado sin reajustar el sistema.



# Agente RAG para consultar 10-K



¿Preguntas?

