

Resumen de la ejecución del holdout del profesor

Práctica Agente RAG sobre informes 10-K

Ejecución. Se evaluó el agente final, sin modificarlo después de conocer el holdout, sobre las 10 preguntas facilitadas por el profesor. Se mantuvieron el mismo modelo, prompt, herramientas, retrieval híbrido, guardrail y configuración de evaluación.

Resultados principales

Métrica	Golden propio	Holdout profesor
Accuracy	20/20 = 100 %	8/10 = 80 %
Recall@5	61,5 %	57,1 %
Coste medio/pregunta	\$0,0122	\$0,0131
Latencia media	8,73 s	8,92 s
Llamadas/pregunta	4,05	4,20

Interpretación

- El sistema acertó las 8 preguntas cuya respuesta el benchmark consideraba disponible en el corpus.
- Los dos únicos fallos fueron los dos casos negativos diseñados para medir abstención ante información considerada fuera del corpus.
- Por familias: extractivas 3/3, comparativas 4/4 y numéricas 1/3. Los dos fallos numéricos corresponden precisamente a los casos de abstención.
- El recall@5 directo fue 57,1 %, pero el agente alcanzó 100 % de acierto en las preguntas respondibles gracias a reformulaciones, iteraciones y combinación de herramientas.

Diagnóstico de los dos fallos

ho-005 (Amazon Gross Profit): el agente detectó que el concepto no estaba disponible en XBRL y no inventó una cifra, pero continuó buscando contexto textual y devolvió fuente="texto" en lugar de fuente="ninguna". Es un fallo formal de abstención/routing, no una alucinación numérica.

ho-006 (NVIDIA FY2023): el agente comprobó que el corpus indexado solo cubría FY2024 y FY2025, pero encontró la cifra de 2023 dentro de una tabla comparativa del 10-K de 2024 y la utilizó. Según la definición del holdout, debía abstenerse. Este caso muestra que el sistema distingue peor entre “dato mencionado en un documento” y “ejercicio soportado por el corpus”.

Conclusión

El resultado agregado fue 80 %, pero la lectura más informativa es 8/8 en preguntas respondibles y 0/2 en preguntas de abstención. El holdout confirma el buen funcionamiento del sistema para extracción, comparación y combinación de XBRL con texto, y señala como principal limitación la necesidad de una política de abstención más estricta para consultas fuera del universo soportado. No se modifica el agente tras conocer el holdout para evitar tuning sobre test.

Evaluación posterior al congelado del sistema final